

Compendio de Variables y Guía Metodológica para el Análisis del High School Longitudinal Study of 2009 (HSLS:09)

Sección I: Introducción a la Fuente de Datos: El High School Longitudinal Study of 2009 (HSLS:09)

Este informe proporciona una descripción exhaustiva y una guía metodológica para un conjunto seleccionado de variables del *High School Longitudinal Study of 2009* (HSLS:09). El objetivo es dotar a los investigadores de la información necesaria para utilizar estos datos de manera precisa y rigurosa en análisis estadísticos, particularmente en aquellos diseñados para explorar relaciones causales en el ámbito educativo. La correcta interpretación de cualquier variable comienza con una comprensión profunda del estudio del que procede.

1.1. Visión General y Propósito

El HSLS:09 es el quinto de una serie de estudios longitudinales secundarios a gran escala, realizados por el Centro Nacional de Estadísticas de la Educación (NCES), una entidad dentro del Instituto de Ciencias de la Educación del Departamento de Educación de los Estados Unidos.¹ Estos estudios representan uno de los esfuerzos más significativos para comprender la trayectoria educativa y vital de los jóvenes en los Estados Unidos. El propósito fundamental del HSLS:09 es monitorear la transición de una muestra nacional de jóvenes desde sus experiencias en la escuela secundaria hasta sus años postsecundarios, incluyendo la educación superior, la inserción en el mercado laboral y la asunción de otros roles adultos.¹

El estudio fue diseñado para responder a preguntas de investigación críticas sobre las trayectorias de los estudiantes. Las preguntas centrales exploran los planes de transición de la educación secundaria a la postsecundaria y la evolución de dichos planes a lo largo del

tiempo; las rutas de entrada y salida de los campos de la ciencia, la tecnología, la ingeniería y las matemáticas (STEM); y las experiencias educativas y sociales que influyen en estas decisiones y trayectorias.² Esta focalización en los procesos de toma de decisiones y en las influencias contextuales hace que el HSLS:09 sea un recurso de datos excepcionalmente rico para investigar los factores que determinan el éxito académico y profesional.

1.2. Diseño del Estudio y Población

La potencia y generalizabilidad de los hallazgos derivados del HSLS:09 residen en su riguroso diseño muestral. El estudio comenzó en el otoño de 2009 con una cohorte de más de 23,000 estudiantes de noveno grado, distribuidos en 944 escuelas secundarias públicas y privadas de todo Estados Unidos.² La selección de esta cohorte se realizó mediante una metodología de muestreo aleatorio estratificado en dos etapas.¹ En la primera etapa, se seleccionó una muestra estratificada de escuelas. En la segunda etapa, se seleccionó aleatoriamente a los estudiantes dentro de cada una de las escuelas participantes.

Este diseño de muestreo complejo no es un mero detalle técnico; es un factor fundamental que condiciona cualquier análisis estadístico que se realice con los datos. Un diseño de muestreo estratificado y por conglomerados (escuelas) implica que las observaciones no son independientes y que ciertos subgrupos de la población pueden haber sido sobremuestreados intencionadamente para garantizar una representación adecuada. Por lo tanto, cada estudiante en el conjunto de datos no se representa solo a sí mismo, sino a un número determinado de estudiantes en la población estadounidense. Para corregir esta disparidad en la probabilidad de selección y para asegurar que las estimaciones sean representativas a nivel nacional, el HSLS:09 incluye un conjunto de pesos de análisis o ponderaciones (survey weights).² La aplicación del peso de análisis adecuado es un paso metodológico indispensable. Omitir el uso de estas ponderaciones en un análisis estadístico llevaría a estimaciones de parámetros sesgadas, errores estándar incorrectos y, en última instancia, a conclusiones que no pueden ser generalizadas válidamente a la población de estudiantes de noveno grado de 2009 en los Estados Unidos.

1.3. Olas de Recopilación de Datos Longitudinales

La naturaleza longitudinal del HSLS:09 es su principal fortaleza, ya que permite a los investigadores seguir a la misma cohorte de individuos a lo largo del tiempo. Esta estructura es esencial para establecer la temporalidad necesaria en los modelos de inferencia causal.

Los datos se recopilaron en múltiples olas, y las variables seleccionadas para este informe provienen de diferentes momentos del estudio, reflejando una secuencia lógica de contexto, experiencia y resultado.⁸

- **Ola Base (Base Year, 2009):** Realizada cuando la cohorte estaba en 9º grado. Se recopilaron datos de los estudiantes, sus padres, profesores de matemáticas y ciencias, y administradores y consejeros escolares. Esta ola es la fuente de las variables de contexto y confusores (aquellas con prefijos X1, A1, C1), que capturan las características iniciales del estudiante, su familia y su entorno escolar.
- **Primer Seguimiento (First Follow-up, 2012):** Realizado en la primavera de 2012, cuando la mayoría de los estudiantes estaban en 11º grado.
- **Actualización de 2013 y Expedientes Académicos de Secundaria (2013 Update & High School Transcripts):** Se recopilaron datos después de la fecha esperada de graduación de la secundaria. De esta ola provienen los expedientes académicos, que son la fuente de variables objetivas sobre el rendimiento y la selección de cursos, como los créditos en cursos avanzados y los promedios de calificaciones (GPA). Estas son las variables con prefijo X3.¹¹
- **Segundo Seguimiento y Expedientes Académicos Postsecundarios (2016 Follow-up & PETS, 2017-18):** Se recopilaron datos sobre las experiencias postsecundarias y laborales de la cohorte. Los expedientes académicos postsecundarios (PETS-SR) proporcionan datos sobre el rendimiento en la educación superior. De esta ola provienen las variables de resultado a más largo plazo, como el GPA universitario (variables con prefijo X5).¹¹

El conjunto de variables solicitado para este informe constituye una sección transversal cuidadosamente seleccionada de todo el diseño longitudinal. Refleja una estructura de investigación causal implícita: las variables de la Ola Base (X1) actúan como condiciones preexistentes o confusores; las variables de los expedientes académicos de secundaria (X3) pueden ser consideradas como variables de "tratamiento" o mediadoras que representan las experiencias académicas; y las variables de resultado (X3 y X5) miden los efectos a corto y largo plazo. Esta estructura temporal inherente a los datos permite modelar cómo el contexto inicial influye en las decisiones y el rendimiento en la secundaria, y cómo estos, a su vez, impactan en el éxito postsecundario.

Sección II: Guía para la Arquitectura de Variables y Convenciones de Datos del HSLS:09

Para utilizar eficazmente el conjunto de datos del HSLS:09, es imprescindible comprender su arquitectura interna, incluyendo las convenciones de nomenclatura de variables y los códigos

estándar para los datos faltantes. Este conocimiento previo facilita la preparación de los datos y previene errores comunes en el análisis.

2.1. Decodificación de los Nombres de Variables del HSLs:09

El NCES emplea un sistema de nomenclatura de variables altamente estructurado y consistente en todos sus estudios longitudinales. Comprender esta convención permite al investigador identificar rápidamente la fuente, el momento y la naturaleza de cualquier variable.¹⁴ La estructura general es la siguiente:

- **Primer Carácter (Fuente/Componente):** Indica el origen de la información.
 - X: Variable compuesta (Composite), derivada de una o más preguntas o fuentes. La mayoría de las variables de alto nivel analítico son de este tipo.
 - S: Cuestionario del estudiante (Student).
 - P: Cuestionario de los padres (Parent).
 - A: Cuestionario del administrador escolar (Administrator).
 - C: Cuestionario del consejero escolar (Counselor).
- **Segundo Carácter (Ola/Ronda de Recopilación):** Indica el momento en que se recopiló la información.
 - 1: Ola Base (Base Year, 2009).
 - 2: Primer Seguimiento (First Follow-up, 2012).
 - 3: Actualización de 2013 o datos de los expedientes académicos de secundaria (2013 Update / High School Transcript).
 - 5: Datos postsecundarios, derivados del Segundo Seguimiento de 2016 o del estudio de expedientes académicos postsecundarios (PETS) de 2017.

Por ejemplo, la variable X1PAREDU puede ser decodificada como una variable compuesta (X) de la Ola Base (1) que se refiere a la educación de los padres. De manera similar, X3TGPAACAD es una variable compuesta (X) derivada de los expedientes académicos de secundaria (3) que representa el GPA académico total. Este sistema no solo es una herramienta de organización, sino también un recurso analítico que ayuda a establecer la secuencia temporal de las mediciones, un requisito previo para cualquier afirmación de causalidad.

2.2. Códigos Estándar para Datos Faltantes

En cualquier estudio por encuesta, los datos faltantes son una realidad. El NCES utiliza un

conjunto de códigos numéricos estandarizados para especificar la razón por la que un dato está ausente. Es fundamental que estos códigos sean tratados adecuadamente durante la fase de limpieza de datos y no sean interpretados erróneamente como valores numéricos válidos.

Código	Etiqueta	Descripción
-9	No Aplicable / Salto Legítimo	El encuestado no respondió a la pregunta porque una respuesta anterior lo excluyó de la secuencia lógica del cuestionario. Este tipo de dato faltante no suele ser problemático.
-8	No Respuesta a la Unidad	Faltan todos los datos de un encuestado para un instrumento completo (p. ej., el cuestionario de los padres no fue completado).
-7	No Respuesta al Ítem / Rechazo	El encuestado fue preguntado pero se negó a responder o no sabía la respuesta.
-6	Valor del Componente Suprimido	En una variable compuesta, uno de los componentes necesarios para su cálculo estaba ausente.
-5	Dato Suprimido por Confidencialidad	El valor ha sido eliminado del archivo de datos para proteger la identidad del encuestado.

La distinción entre estos códigos es analíticamente importante. Por ejemplo, un gran número de valores -9 en una variable puede confirmar la correcta implementación de la lógica del cuestionario. Por el contrario, un alto porcentaje de valores -7 en una pregunta sensible, como los ingresos familiares, puede indicar un posible sesgo de no respuesta que debe ser

investigado. La simple eliminación de todos los casos con datos faltantes (eliminación por lista) es una práctica desaconsejada, ya que puede reducir drásticamente el tamaño de la muestra e introducir sesgos si los datos no faltan completamente al azar.¹⁵

2.3. Archivos de Datos de Uso Público vs. Uso Restringido

El NCES distribuye los datos del HSLS:09 en dos formatos principales: archivos de uso público y archivos de uso restringido.⁴

- **Archivos de Uso Público (Public-Use Files):** Están disponibles para su descarga directa por parte del público general. Para proteger la confidencialidad de los encuestados, estos archivos han sido sometidos a procedimientos de anonimización. Esto puede incluir la agregación de categorías en variables sensibles (p. ej., agrupar razas/etnias con pocos encuestados en una categoría de "Otro"), el "top-coding" de variables continuas (p. ej., establecer un límite superior para los ingresos), o la eliminación de identificadores geográficos detallados.⁴
- **Archivos de Uso Restringido (Restricted-Use Files):** Contienen datos más detallados y potencialmente identificables. El acceso a estos archivos requiere un proceso de solicitud formal y la obtención de una licencia del NCES. Estos archivos son necesarios para análisis que requieren un alto nivel de granularidad geográfica o demográfica.

La elección entre un archivo de uso público y uno de uso restringido tiene implicaciones directas para el análisis. Por ejemplo, la variable X1RACE en el archivo de uso público puede agrupar a los "Nativos de Hawái/Isleños del Pacífico" con otras categorías debido al pequeño tamaño de la muestra, como se indica en la documentación.⁴ De manera similar, X1FAMINCOME se presenta en rangos en el archivo público, mientras que podría estar disponible de forma más continua en el archivo restringido. Los investigadores deben ser conscientes de que el archivo de datos que utilicen puede afectar el nivel de detalle de sus variables y, por lo tanto, el alcance de sus conclusiones. El presente informe se basa principalmente en la estructura y los valores esperados en los archivos de uso público, que son los más accesibles.

Sección III: Compendio Detallado de Variables

Esta sección constituye el núcleo del informe, proporcionando una descripción detallada de cada una de las 21 variables solicitadas. Se inicia con una tabla resumen para una referencia

rápida, seguida de un desglose exhaustivo de cada variable, organizada según la estructura causal propuesta: llaves de unión, confusores, tratamiento y resultado.

Tabla 3.1: Resumen de Variables Seleccionadas del HSLs:09

Variable	Descripción Breve	Tipo de Dato	Fuente y Ola
Llaves de Unión			
STU_ID	Identificador único del estudiante	Integer	Todas
SCH_ID	Identificador único de la escuela	Integer	Ola Base
Confusores			
X3TGPA9TH	GPA del estudiante en 9º grado	Float	Expediente Académico (2013)
X1TXMTH	Aptitud matemática inicial (puntaje estandarizado)	Float	Ola Base (2009)
X1PAREDU	Nivel educativo más alto de los padres	Categórica Ordinal	Ola Base (2009)
X1FAMINCOME	Ingreso familiar anual	Categórica Ordinal	Ola Base (2009)
X1POVERTY	Indicador de pobreza (umbral del 100%)	Binaria	Ola Base (2009)
X1POVERTY130	Indicador de pobreza (umbral del 130%)	Binaria	Ola Base (2009)

X1PAR1EMP	Estado laboral del sustentador principal	Categórica Nominal	Ola Base (2009)
X1SEX	Sexo biológico del estudiante	Categórica Nominal	Ola Base (2009)
X1RACE	Etnia/raza del estudiante	Categórica Nominal	Ola Base (2009)
X1STDOB	Fecha de nacimiento del estudiante	Fecha (MM/YYYY)	Ola Base (2009)
Tratamiento			
C1GETAHEAD	Escuela ofrece cursos de verano para adelantar	Binaria	Ola Base (2009)
X3TCREDADV	Créditos totales en cursos avanzados (AP/IB)	Float	Expediente Académico (2013)
X3TCREDHON	Créditos totales en cursos "Honors"	Float	Expediente Académico (2013)
X5DUALCRSFLG	Estudiante cursó asignaturas "dual credit"	Binaria	Postsecundaria (2017)
A1G9STUDY	Escuela enseña técnicas de estudio en 9º grado	Binaria	Ola Base (2009)
Resultado			
X3TGPAACAD	GPA académico general acumulado	Float	Expediente Académico (2013)

	en secundaria		
X3TGPA12TH	GPA obtenido en 12º grado	Float	Expediente Académico (2013)
X5GPAALL	GPA promedio en todas las instituciones postsecundarias	Float	Postsecundaria (2017)
X3TXSATCOMP	Puntaje combinado en pruebas SAT/ACT	Float	Expediente Académico (2013)

3.1. Llaves de Unión (Claves de Identificación)

Estas variables son identificadores numéricos anónimos que no contienen información intrínseca, pero son cruciales para la gestión de la base de datos, especialmente para fusionar archivos de diferentes fuentes (p. ej., estudiante, padre, escuela) o de diferentes olas del estudio.

- **Nombre de la Variable:** STU_ID
- **Etiqueta Descriptiva:** Student ID
- **Descripción:** Un identificador numérico único asignado a cada estudiante en la muestra del HSLS:09. Este ID es consistente a lo largo de todas las olas y archivos de datos, permitiendo vincular la información de un mismo estudiante a lo largo del tiempo.
- **Fuente y Ola:** Todas
- **Tipo de Dato:** Integer (Entero)
- **Posibles Valores y Códigos:** Un valor entero único para cada uno de los más de 23,000 estudiantes de la muestra.
- **Nombre de la Variable:** SCH_ID
- **Etiqueta Descriptiva:** School ID
- **Descripción:** Un identificador numérico único asignado a cada escuela que participó en la Ola Base del estudio. Permite vincular a todos los estudiantes que pertenecen a la misma escuela y fusionar datos a nivel escolar (provenientes de los cuestionarios de administradores y consejeros) con los datos a nivel de estudiante.
- **Fuente y Ola:** Ola Base (2009)
- **Tipo de Dato:** Integer (Entero)
- **Posibles Valores y Códigos:** Un valor entero único para cada una de las 944 escuelas

de la muestra.

3.2. Confusores (Variables de Contexto – Ola Base X1/X3)

Estas variables capturan las características iniciales de los estudiantes y sus entornos, que son fundamentales como variables de control en modelos estadísticos para aislar el efecto de las variables de tratamiento.

Habilidad Previa

- **Nombre de la Variable:** X3TGPA9TH
- **Etiqueta Descriptiva:** HS transcript 9th grade GPA
- **Descripción:** Variable compuesta que representa el promedio general de calificaciones (GPA) del estudiante al finalizar el 9º grado. Se calcula a partir de los expedientes académicos de secundaria recopilados en 2013. Es un indicador clave del rendimiento académico temprano en la secundaria.
- **Fuente y Ola:** Expediente Académico de Secundaria (2013)
- **Tipo de Dato:** Float (Decimal)
- **Posibles Valores y Códigos:** Un valor numérico continuo, típicamente en una escala de 0.00 a 4.00. Puede exceder 4.00 en sistemas de calificación ponderados. Se deben consultar los códigos de datos faltantes estándar (p. ej., -9, -7).
- **Nombre de la Variable:** X1TXMTH
- **Etiqueta Descriptiva:** Base-year math IRT-scaled score
- **Descripción:** Un puntaje estandarizado que mide la aptitud matemática del estudiante en 9º grado. Este puntaje se deriva de una evaluación de matemáticas administrada durante la Ola Base, que se centra en habilidades algebraicas. El puntaje se calcula utilizando la Teoría de Respuesta al Ítem (IRT), que proporciona una medida más robusta de la habilidad latente que un simple recuento de respuestas correctas. Los puntajes suelen estar estandarizados con una media de 50 y una desviación estándar de 10.
- **Fuente y Ola:** Evaluación del Estudiante, Ola Base (2009)
- **Tipo de Dato:** Float (Decimal)
- **Posibles Valores y Códigos:** Un valor numérico continuo. Se deben consultar los códigos de datos faltantes estándar.

Familia

- **Nombre de la Variable:** X1PAREDU
- **Etiqueta Descriptiva:** Parents' highest level of education-composite
- **Descripción:** Variable compuesta categórica y ordinal que indica el nivel educativo más alto alcanzado por cualquiera de los padres o tutores del estudiante. Se construye a partir de las respuestas del cuestionario de los padres en la Ola Base.
- **Fuente y Ola:** Cuestionario de los Padres, Ola Base (2009)
- **Tipo de Dato:** Categórica Ordinal
- **Posibles Valores y Códigos:**

Código	Etiqueta
1	Less than high school
2	High school diploma or equivalent
3	Certificate/license
4	Some college/Associate's degree
5	Bachelor's degree
6	Master's degree
7	Doctorate or professional degree (PhD, MD, JD)

- **Nombre de la Variable:** X1FAMINCOME
- **Etiqueta Descriptiva:** Total family income from all sources 2008
- **Descripción:** Variable compuesta categórica y ordinal que representa el ingreso familiar total de todas las fuentes durante el año 2008, según lo informado por los padres en la Ola Base de 2009. En los archivos de uso público, esta variable se presenta en rangos para proteger la confidencialidad.
- **Fuente y Ola:** Cuestionario de los Padres, Ola Base (2009)
- **Tipo de Dato:** Categórica Ordinal
- **Posibles Valores y Códigos:**

Código	Etiqueta (Rango de Ingreso Anual en USD)
--------	--

1	\$15,000 or less
2	\$15,001 - \$35,000
3	\$35,001 - \$55,000
4	\$55,001 - \$75,000
5	\$75,001 - \$95,000
6	\$95,011 - \$115,000
7	\$115,001 - \$135,000
8	\$135,001 - \$155,000
9	\$155,001 - \$175,000
10	\$175,001 - \$195,000
11	\$195,001 - \$215,000
12	\$215,001 or more

- **Nombre de la Variable:** X1POVERTY y X1POVERTY130
- **Etiqueta Descriptiva:** Poverty indicator (100% threshold) / Poverty indicator (130% threshold)
- **Descripción:** Variables binarias compuestas que indican si el ingreso familiar del estudiante está por debajo de los umbrales federales de pobreza. X1POVERTY utiliza el umbral del 100%, mientras que X1POVERTY130 utiliza el umbral del 130%, que a menudo se usa para determinar la elegibilidad para programas como el almuerzo a precio reducido. Se calculan utilizando el ingreso familiar y el tamaño del hogar.
- **Fuente y Ola:** Cuestionario de los Padres, Ola Base (2009)
- **Tipo de Dato:** Binaria
- **Posibles Valores y Códigos:**

Código	Etiqueta
0	At or above poverty threshold

1	Below poverty threshold
---	-------------------------

- **Nombre de la Variable:** X1PAR1EMP
- **Etiqueta Descriptiva:** Parent 1's employment status
- **Descripción:** Variable categórica nominal que describe la situación laboral del padre, madre o tutor principal del hogar, según lo informado en la Ola Base.
- **Fuente y Ola:** Cuestionario de los Padres, Ola Base (2009)
- **Tipo de Dato:** Categórica Nominal
- **Posibles Valores y Códigos:**

Código	Etiqueta
1	Working full-time
2	Working part-time
3	Unemployed and looking for work
4	Homemaker
5	Temporarily laid off, sick, or disabled
6	Retired
7	In school
8	Other

Estudiante

- **Nombre de la Variable:** X1SEX
- **Etiqueta Descriptiva:** X1 Student's sex
- **Descripción:** Variable categórica nominal que indica el sexo del estudiante, recopilada en la Ola Base.
- **Fuente y Ola:** Cuestionario del Estudiante/Registros Escolares, Ola Base (2009)
- **Tipo de Dato:** Categórica Nominal
- **Posibles Valores y Códigos:** ¹⁷

Código	Etiqueta
1	Male
2	Female

- **Nombre de la Variable:** X1RACE
- **Etiqueta Descriptiva:** X1 Student's race/ethnicity-composite
- **Descripción:** Variable compuesta categórica nominal que identifica la raza o etnia del estudiante. Esta variable se construye a partir de múltiples fuentes (estudiante, padres) para obtener la mejor clasificación posible.
- **Fuente y Ola:** Compuesta, Ola Base (2009)
- **Tipo de Dato:** Categórica Nominal
- **Posibles Valores y Códigos:** ¹⁷

Código	Etiqueta
1	Amer. Indian/Alaska Native, non-Hispanic
2	Asian, non-Hispanic
3	Black/African-American, non-Hispanic
4	Hispanic, no race specified
5	Hispanic, race specified
6	More than one race, non-Hispanic
7	Native Hawaiian/Pacific Islander, non-Hispanic
8	White, non-Hispanic

- **Nombre de la Variable:** X1STDOB
- **Etiqueta Descriptiva:** Student's date of birth-composite
- **Descripción:** Variable compuesta que indica la fecha de nacimiento del estudiante. En los archivos de uso público, generalmente se proporciona solo el mes y el año para proteger la confidencialidad. Es útil para calcular la edad exacta del estudiante en diferentes puntos del estudio.

- **Fuente y Ola:** Compuesta, Ola Base (2009)
- **Tipo de Dato:** Fecha (formato MM/YYYY en archivos públicos)
- **Posibles Valores y Códigos:** Valores de mes y año (p. ej., 03/1995).

3.3. Tratamiento (Variables de Experiencias Académicas)

Estas variables representan las experiencias, exposiciones y cursos que los estudiantes encontraron durante la secundaria. En un modelo causal, pueden ser consideradas como las variables de "tratamiento" cuyo efecto sobre los resultados se desea medir.

- **Nombre de la Variable:** C1GETAHEAD
- **Etiqueta Descriptiva:** School offers summer session to get ahead
- **Descripción:** Variable binaria del cuestionario del consejero escolar de la Ola Base que indica si la escuela ofrece programas o sesiones de verano que permiten a los estudiantes tomar cursos para obtener créditos y adelantar en su programa de estudios.
- **Fuente y Ola:** Cuestionario del Consejero Escolar, Ola Base (2009)
- **Tipo de Dato:** Binaria
- **Posibles Valores y Códigos:**

Código	Etiqueta
0	No
1	Yes

- **Nombre de la Variable:** X3TCREDADV
- **Etiqueta Descriptiva:** HS transcript total advanced placement/international baccalaureate credits
- **Descripción:** Variable continua (float) derivada de los expedientes académicos de secundaria. Mide el número total de créditos Carnegie que un estudiante obtuvo en cursos de Colocación Avanzada (AP) o Bachillerato Internacional (IB) durante toda su carrera en la secundaria.
- **Fuente y Ola:** Expediente Académico de Secundaria (2013)
- **Tipo de Dato:** Float (Decimal)
- **Posibles Valores y Códigos:** Un valor numérico no negativo que representa el total de créditos (p. ej., 0.0, 1.0, 2.5).
- **Nombre de la Variable:** X3TCREDHON
- **Etiqueta Descriptiva:** HS transcript total honors credits
- **Descripción:** Variable continua (float) derivada de los expedientes académicos de secundaria. Mide el número total de créditos Carnegie que un estudiante obtuvo en

cursos designados como "Honors" (de honor o alta exigencia), excluyendo los cursos AP/IB.

- **Fuente y Ola:** Expediente Académico de Secundaria (2013)
- **Tipo de Dato:** Float (Decimal)
- **Posibles Valores y Códigos:** Un valor numérico no negativo.
- **Nombre de la Variable:** X5DUALCRSFLG
- **Etiqueta Descriptiva:** Took dual credit course in high school
- **Descripción:** Variable binaria compuesta, creada a partir de los datos de los expedientes académicos postsecundarios. Indica si el estudiante tomó algún curso de "crédito dual" (dual credit) durante la secundaria. Estos cursos otorgan simultáneamente créditos de secundaria y de nivel universitario.
- **Fuente y Ola:** Compuesta, Datos Postsecundarios (2017)
- **Tipo de Dato:** Binaria
- **Posibles Valores y Códigos:**

Código	Etiqueta
0	Did not take dual credit courses
1	Took one or more dual credit courses

- **Nombre de la Variable:** A1G9STUDY
- **Etiqueta Descriptiva:** School teaches study skills in 9th grade
- **Descripción:** Variable binaria del cuestionario del administrador escolar de la Ola Base. Indica si la escuela, como parte de su currículo formal para el 9º grado, enseña o promueve activamente técnicas y habilidades de estudio.
- **Fuente y Ola:** Cuestionario del Administrador Escolar, Ola Base (2009)
- **Tipo de Dato:** Binaria
- **Posibles Valores y Códigos:**

Código	Etiqueta
0	No
1	Yes

3.4. Resultado (Variables de Logro Académico)

Estas variables miden el rendimiento y los logros académicos de los estudiantes, tanto al final de la secundaria como en la etapa postsecundaria. Funcionan como las variables dependientes o de resultado en un análisis.

- **Nombre de la Variable:** X3TGPAACAD
- **Etiqueta Descriptiva:** HS transcript overall academic GPA
- **Descripción:** Variable continua (float) derivada de los expedientes académicos de secundaria. Representa el GPA acumulado del estudiante en todos sus cursos académicos (típicamente excluyendo materias como educación física, arte o música, a menos que sean de nivel avanzado). Es una medida global del rendimiento académico en la secundaria.
- **Fuente y Ola:** Expediente Académico de Secundaria (2013)
- **Tipo de Dato:** Float (Decimal)
- **Posibles Valores y Códigos:** Un valor numérico, típicamente en una escala de 0.00 a 4.00.
- **Nombre de la Variable:** X3TGPA12TH
- **Etiqueta Descriptiva:** HS transcript 12th grade GPA
- **Descripción:** Variable continua (float) derivada de los expedientes académicos. Representa el GPA del estudiante calculado únicamente con los cursos tomados durante el 12º grado. Mide el rendimiento en el último año de secundaria.
- **Fuente y Ola:** Expediente Académico de Secundaria (2013)
- **Tipo de Dato:** Float (Decimal)
- **Posibles Valores y Códigos:** Un valor numérico, típicamente en una escala de 0.00 a 4.00.
- **Nombre de la Variable:** X5GPAALL
- **Etiqueta Descriptiva:** All postsecondary institutions GPA
- **Descripción:** Variable continua (float) compuesta, derivada del estudio de expedientes académicos postsecundarios (PETS-SR) de 2017. Representa el GPA acumulado del estudiante en todas las instituciones de educación superior a las que asistió hasta esa fecha. Es un indicador clave del rendimiento académico postsecundario.
- **Fuente y Ola:** Expediente Académico Postsecundario (2017)
- **Tipo de Dato:** Float (Decimal)
- **Posibles Valores y Códigos:** Un valor numérico, típicamente en una escala de 0.00 a 4.00.
- **Nombre de la Variable:** X3TXSATCOMP
- **Etiqueta Descriptiva:** SAT/ACT composite score
- **Descripción:** Variable continua (float) compuesta que representa un puntaje estandarizado combinado de las pruebas de aptitud universitaria SAT y/o ACT. El NCES obtiene estos datos a través de convenios con las organizaciones que administran las pruebas.⁸ Los puntajes de ACT se convierten a la escala del SAT para crear un único puntaje comparable, que sirve como un indicador estandarizado de la preparación para la universidad.
- **Fuente y Ola:** Datos Administrativos (vinculados en 2013)

- **Tipo de Dato:** Float (Decimal)
- **Posibles Valores y Códigos:** Un valor numérico en la escala del SAT (típicamente de 400 a 1600 en la escala actual, o 600 a 2400 en la escala vigente durante el estudio).

Sección IV: Recomendaciones para el Análisis de Datos y Mejores Prácticas

La disponibilidad de un conjunto de datos tan rico como el HSLs:09 conlleva la responsabilidad de analizarlo de manera metodológicamente sólida. Las siguientes recomendaciones están diseñadas para guiar al investigador en la aplicación de las mejores prácticas analíticas.

4.1. El Rol Crítico de los Pesos Muestrales (Survey Weights)

Como se mencionó en la Sección I, el HSLs:09 utiliza un diseño de muestreo complejo. Ignorar este diseño y tratar los datos como si provinieran de una muestra aleatoria simple es un error metodológico grave. Para producir estimaciones que sean representativas de la población nacional de estudiantes de noveno grado de 2009, es imperativo utilizar los pesos de análisis (survey weights) proporcionados en los archivos de datos.²

La variable de ponderación adecuada dependerá del alcance del análisis. Por ejemplo, para un análisis que utiliza datos de estudiantes de la Ola Base, la variable de ponderación W1STUDENT sería la apropiada. El software estadístico moderno (como Stata, R, SAS o SPSS) tiene procedimientos específicos para incorporar estos pesos, que no solo ajustan las estimaciones puntuales (medias, proporciones, coeficientes de regresión), sino que también calculan los errores estándar de manera correcta, teniendo en cuenta la estratificación y el agrupamiento (cluster) del diseño muestral. El no hacerlo puede llevar a una subestimación de los errores estándar y, por lo tanto, a una mayor probabilidad de cometer un error de Tipo I (es decir, encontrar efectos estadísticamente significativos donde no los hay).

4.2. Manejo de Datos Faltantes

El manejo de los datos faltantes es un desafío central en la investigación longitudinal, donde

la atrición (pérdida de participantes a lo largo del tiempo) puede ser una fuente importante de sesgo. El primer paso es codificar correctamente los distintos tipos de valores faltantes del NCES (ver Sección 2.2) para que el software estadístico los reconozca como tales y no los incluya en los cálculos.

La estrategia de eliminación por lista (listwise deletion), que consiste en descartar cualquier caso que tenga un valor faltante en cualquiera de las variables del modelo, es generalmente la peor opción. Puede reducir drásticamente el poder estadístico y, lo que es más importante, introducir un sesgo severo si las razones por las que faltan los datos están relacionadas con las variables del estudio.¹⁵ Se recomienda encarecidamente el uso de técnicas más avanzadas. La imputación múltiple (Multiple Imputation) es actualmente el método de referencia. Este procedimiento crea varios conjuntos de datos completos, donde los valores faltantes se reemplazan con valores plausibles extraídos de una distribución, y luego combina los resultados del análisis de cada conjunto de datos para producir estimaciones y errores estándar que tienen en cuenta la incertidumbre asociada con los datos faltantes.

4.3. Estructuración de un Modelo Causal

El conjunto de variables seleccionado está inherentemente estructurado para un análisis causal o cuasi-experimental. El diseño longitudinal del HSLs:09 establece un orden temporal claro entre las mediciones, lo cual es una condición necesaria (aunque no suficiente) para la inferencia causal. Un modelo analítico robusto debe respetar esta temporalidad.

1. **Variables de Confusión/Control:** Las variables de la Ola Base (X1...) y las de rendimiento previo (X3TGPA9TH, X1TXMTH) deben ser tratadas como condiciones preexistentes. Deben incluirse en los modelos de regresión como variables de control para tener en cuenta las diferencias iniciales entre los estudiantes. Esto ayuda a aislar el efecto de las experiencias posteriores, reduciendo el sesgo de variable omitida.
2. **Variables de Tratamiento/Mediación:** Las variables que describen las experiencias académicas en la secundaria (X3TCREDADV, X3TCREDHON, X5DUALCRSFLG, etc.) deben ser modeladas como variables independientes o mediadoras que ocurren después de las condiciones iniciales pero antes de los resultados finales.
3. **Variables de Resultado:** Las variables de rendimiento académico (X3TGPAACAD, X3TGPA12TH, X5GPAALL, X3TXSATCOMP) deben ser las variables dependientes en el modelo.

Al estructurar el análisis de esta manera, el investigador puede estimar el efecto de, por ejemplo, tomar cursos avanzados (X3TCREDADV) sobre el GPA universitario (X5GPAALL), mientras se controla por la habilidad matemática inicial (X1TXMTH) y el estatus socioeconómico familiar (X1FAMINCOME). Este enfoque transforma el análisis de una simple descripción de correlaciones a una investigación más rigurosa de las posibles relaciones

causales que dan forma a las trayectorias educativas de los estudiantes.

Fuentes citadas

1. High School Longitudinal Study of 2009 (HSLs:09): Base-Year Data File Documentation - National Center for Education Statistics (NCES), acceso: octubre 24, 2025, https://nces.ed.gov/surveys/hsls09/pdf/2011328_1.pdf
2. High School Longitudinal Study, 2009-2013 [United States] (ICPSR 36423), acceso: octubre 24, 2025, <https://www.icpsr.umich.edu/web/NADAC/studies/36423>
3. High School Longitudinal Study of 2009 (HSLs:09) - RTI International, acceso: octubre 24, 2025, <https://www.rti.org/impact/high-school-longitudinal-study-2009>
4. FCSM | ICSP Agencies' | High School Longitudinal Study of 2009 (HSLs:09), acceso: octubre 24, 2025, <https://nces.ed.gov/fCSM/hsls09.asp>
5. High School Longitudinal Study of 2009 - Dataset - Catalog, acceso: octubre 24, 2025, <https://catalog.data.gov/dataset/high-school-longitudinal-study-of-2009-af1b6>
6. High School Longitudinal Study of 2009, acceso: octubre 24, 2025, <https://www.datalumos.org/datalumos/project/218363/version/V1/view>
7. High School Longitudinal Study, 2009-2013 [United States] (ICPSR 36423), acceso: octubre 24, 2025, <https://www.icpsr.umich.edu/icpsrweb/NADAC/studies/36423>
8. High School Longitudinal Study of 2009 (HSLs:09) Panel Maintenance 2018 & 2021 - Regulations.gov, acceso: octubre 24, 2025, https://downloads.regulations.gov/ED-2018-ICCD-0077-0002/attachment_1.pdf
9. High School Longitudinal Study (HSLs) (source: NCES), acceso: octubre 24, 2025, <https://www.datalumos.org/datalumos/project/237306/view>
10. High School Longitudinal Study of 2009 (HSLs:09) - Overview, acceso: octubre 24, 2025, <https://nces.ed.gov/surveys/hsls09/>
11. High School Longitudinal Study of 2009 (HSLs:09) - Available Data, acceso: octubre 24, 2025, https://nces.ed.gov/surveys/hsls09/hsls09_data.asp
12. High School Longitudinal Study of 2009 (HSLs:09) 2013 Update and High School Transcripts Data File Documentation - National Center for Education Statistics (NCES), acceso: octubre 24, 2025, <https://nces.ed.gov/use-work/resource-library/report/users-manualdata-file-documentation/high-school-longitudinal-study-2009-hsls09-2013-update-and-high-school-transcripts-data-file?pubid=2015036>
13. High School Longitudinal Study of 2009 (HSLs:09) Postsecondary Education Transcript Study and Student Financial Aid Records Collection, acceso: octubre 24, 2025, <https://nces.ed.gov/pubs2020/2020004.pdf>
14. Getting Started with the HSLs:09 Data Page 1 of 7, acceso: octubre 24, 2025, https://nces.ed.gov/training/datauser/HSLs_02/assets/HSLs_02_Transcript.pdf
15. "The High School Longitudinal Study of 2009 using New Statistical Metho" by Arianna Ortiz, acceso: octubre 24, 2025, <https://commons.stmarytx.edu/msrjs/33/>
16. The High School Longitudinal Study of 2009 (HSLs:09) - SciSpace, acceso: octubre 24, 2025,

<https://scispace.com/pdf/the-high-school-longitudinal-study-of-2009-hsIs-09-a-first-59z7ks9lwp.pdf>

17. Battle's Quantitative Methods National Center for Education Statistics High School Longitudinal Study Abridged Codebook (2009, acceso: octubre 24, 2025, <https://juanbattle.com/files/2019/05/Battles-HSLS-Codebook.pdf>)